

```
#Estes programas têm a finalidade de testar a extração de termos de um arquivo PDF.
#
# Desenvolvido por Diego Fernandes Silva [d.nugo]
# diego.fernandes@msn.com | diego.fernandes@ufrgs.br
# dez/2024 - 2025
#
from PyPDF2 import PdfReader

# Definição de variáveis para saída de arquivo de texto contendo conteúdo lido do PDF:
texto_extraido = 'TextoExtraído.txt'

while True:
    try:
        for i in range (50):
            print('#', end='')
            print('')

            print('Insira a seguir o nome do arquivo PDF:\n\n(dica: caso não esteja conseguindo abrir o arquivo, tente renomeá-lo para um termo mais simples e fácil de ser escrito, como por exemplo \'artigo.pdf\'. Certifique-se também que o arquivo esteja localizado na mesma pasta em que este programa executável .\nNOME DO ARQUIVO: ', end='')

            nomepdf = input()
            reader = PdfReader(nomepdf)
            meta = reader.metadata

            # Tenta abrir o arquivo
            with open(nomepdf, 'rb') as file:
                leitor = PdfReader(file)
                print(f'\nO arquivo \'{nomepdf}\'' foi localizado e aberto com sucesso. Estes são os metadados nele encontrados:')
                break
        except FileNotFoundError:
            print(f'\n\nERRO: O arquivo \'{nomepdf}\'' não foi encontrado. Por favor, verifique o nome e o caminho do arquivo e tente novamente.\n\n\n\n')

total_pags = len(reader.pages)
print('Número de páginas: ', len(reader.pages))
print('Autor: ', meta.author)
print('Criador: ', meta.creator)
print('Produtor: ', meta.producer)
print('Assunto: ', meta.subject)
print('Título: ', meta.title)

# Abre o arquivo de saída .txt das páginas extraídas do PDF
with open(texto_extraido, 'w', encoding='utf8') as saida_texto:
    # Ler o conteúdo de cada página
    for pagina in range(total_pags):
        pagina_atual = reader.pages[pagina]
        texto = pagina_atual.extract_text()
        saida_texto.write(f'[[Conteúdo da página {pagina + 1}:]]\n{texto}\n')

print(f'Todo o conteúdo lido do arquivo PDF \'{nomepdf}\'' foi salvo com sucesso no arquivo \'{saida_texto.name}\'. Por favor, confira se o texto está de acordo com o esperado antes de continuar para a análise semântica do documento.')
```